

Plataforma Open Source de Precisión Agronómica para la Detección de Malezas en Caña de Azúcar (Tucumán, Argentina)

Proyecto Tecnológico Integrador (PTI)

Briguera, Octavio · Juárez, Carlos Nahuel · Godoy Cabrera, Santiago Abel · Guerrero, Lautaro · Iriarte, Chamorro Jorge Manuel · Lagoria, Ricardo Augusto

Universidad Blas Pascal – Ingeniería en Informática – Córdoba, Argentina – Mayo 2026 – Versión 1.0

1. Resumen

Se presenta el diseño de una plataforma 100 % open source que integra fotogrametría con drones RGB, detección de malezas mediante deep learning (YOLOv8/v11) e índices de vegetación visibles, con el objetivo de generar mapas de prescripción variable de herbicidas en caña de azúcar para la provincia de Tucumán, Argentina. El sistema procesa imágenes de vuelo RGB mediante OpenDroneMap y PyTorch, enriquece los resultados con imágenes Sentinel-2 (Copernicus/GEE), datos de humedad edafológica (SMAP L4) y pronóstico meteorológico (Open-Meteo/NASA POWER), y produce un JSON georreferenciado por parcela con recomendaciones agronómicas accionables. El resultado esperado es una reducción del 20-35 % en el consumo de herbicidas, alineado con datos del INTA, sobre la base de antecedentes locales documentados por la EEAOC y el INTA Famaillá. El proyecto está planificado para 11 meses con un equipo de seis estudiantes de Ingeniería en Informática y un presupuesto de infraestructura cloud inferior a USD 200.

2. Introducción y Problema

2.1 Contexto regional

Tucumán concentra el 60 % de la producción nacional de caña de azúcar. Según datos del IPAAT, en la zafra 2024 se molieron 17.062.495 t sobre 294.470 ha cosechables, con 14 ingenios activos y 228 días de molienda (IPAAT, reporte final 2024). Las exportaciones del NOA totalizaron 407.539 t. A nivel nacional, la producción alcanzó 24.383.000 t (Centro Azucarero Argentino, 2025).

2.2 La maleza como factor limitante

Las malezas constituyen el principal factor biótico limitante del rendimiento en este cultivo. La literatura internacional reporta pérdidas de entre el 20 % y el 72 % según especie y estadio (Chauhan & Srivastava, 2002). A nivel local, la EEAOC documentó caídas de hasta 21,44 t/ha por competencia con pasto cubano (*Tithonia tubaeformis*) a densidades inferiores a 5 plantas/m² (Revista Avance, EEAOC 2023). En el relevamiento fitosociológico publicado por Cabrera et al. (2020) en La Cocha (Tucumán), se identificaron especies con dominancia creciente en lotes de mayor edad de corte.

Según el último relevamiento de la EEAOC (Avance 2023), las especies más frecuentes en la provincia son:

Nombre común	Nombre científico	Familia	Frecuencia (EEAOC)
Gramma bermuda / Gramilla	<i>Cynodon dactylon</i> (L.) Pers.	Poaceae	49 %
Pasto cubano / Yuyo cubano	<i>Tithonia tubaeformis</i> (Jacq.) Cass.	Asteraceae	64 % (emergente)
Pasto ruso / Sorgo de Alepo	<i>Sorghum halepense</i> (L.) Pers.	Poaceae	~30 %
Tupúlo	<i>Sicyos polyacanthus</i> Cogn.	Cucurbitaceae	~35 %
Cebollín	<i>Cyperus rotundus</i> L.	Cyperaceae	23 %

2.3 Antecedentes y brecha tecnológica

El INTA Famaillá conduce ensayos desde 2015 con drones RGB (DJI Phantom 4) combinando OpenDroneMap, QGIS y algoritmos de IA para detección de fallas de siembra (Ing. Ricardo Rodríguez, INTA Informa). La EEAOC trabaja con imágenes Landsat desde 1997 y Sentinel-2 desde 2015, principalmente para seguimiento de biomasa y área cosechable (Fandos et al., Revista Avance). Sin embargo, ninguno de estos esfuerzos genera un “pipeline” completo que vincule la imagen del dron con una recomendación de herbicida por parcela, con identificación a nivel de especie y mapa de prescripción variable. Esa es la brecha que cierra el presente proyecto.

3. Propuesta Técnica

3.1 Pipeline de procesamiento

El flujo completo, desde el vuelo hasta el JSON de salida, se compone de ocho etapas secuenciales ejecutadas en servidor:

#	Etapas	Descripción
1	Ingesta y validación	Carga de imágenes JPG con EXIF GPS via FastAPI + Celery; metadatos persistidos en PostgreSQL/PostGIS.
2	Ortomosaico	OpenDroneMap (Docker, AGPLv3): genera GeoTIFF, DSM, DTM. Resolución de salida: 5 cm/pixel (ajustable).
3	Preprocesamiento	OpenCV: balance de blanco, normalización, recorte. Rasterio/GDAL: reproyección UTM 20S. Tiling 1024×1024 px.
4	Inferencia CV	YOLOv8n/s (detección/segmentación de malezas) + DeepLabV3+ para segmentación cultivo/maleza/suelo + ResNet-18 para estadio fenológico.
5	Índices de vegetación	ExG, VARI, GLI, MGRVI por celda 1×1 m sobre máscara de vegetación (umbral ExG > Otsu).
6	Enriquecimiento APIs	Sentinel-2 L2A → NDVI, NDWI, NDRE, NDMI (GEE/Copernicus). SMAP L4 → humedad radicular. Open-Meteo → pronóstico 16 d. NASA POWER → ETo.
7	Motor de reglas	Reglas declarativas YAML/JSON editables por agrónomos; generación de recomendaciones por parcela.

8	Persistencia y salida	PostgreSQL/PostGIS + almacenamiento objeto (MinIO). Salida: JSON georreferenciado + WMS + reporte PDF.
---	------------------------------	--

3.2 Stack tecnológico

Componente	Tecnología	Licencia	Función
Fotogrametría	OpenDroneMap	AGPL-3.0	Generación de ortomosaico, DSM, DTM
Detección malezas	YOLOv8/v11 (Ultralytics)	AGPL-3.0	Detección y segmentación de malezas
Segmentación	DeepLabV3+ / U-Net (SMP)	MIT	Segmentación cultivo/maleza/suelo
Geoprosesamiento	Rasterio, GDAL, GeoPandas	BSD/MIT	Manejo de rasters y vectores
APIs satélite	Google Earth Engine, Copernicus DSE	Académico	Sentinel-2: NDVI, NDWI, NDRE, NDMI
Datos hídricos	SMAP L4 (NASA)	Libre	Humedad de suelo (9 km, cada 3 h)
Meteorología	Open-Meteo, NASA POWER	AGPL/CC	Pronóstico 16 d, ETo, histórico
Backend/API	FastAPI + Celery	MIT/BSD	Procesamiento asíncrono, OpenAPI
Base de datos	PostgreSQL 15 + PostGIS 3.4	PostgreSQL/GPL	Datos vectoriales y atributos
Frontend	Leaflet + plugin QGIS	BSD/GPL	Visualización de mapas y reportes
MLOps	MLflow + CVAT	Apache 2.0/MIT	Tracking de experimentos y etiquetado

3.3 Regla agronómica declarativa (YAML)

Las reglas son editables por el agrónomo sin modificar código:

```
# reglas_malezas.yaml
- id: ctrl_cyn_sorg_macollaje
  condicion:
    cobertura_maleza_pct: { gte: 15 }
    especie: ["Cynodon dactylon", "Sorghum halepense"]
    estadio: ["macollaje", "gran_crecimiento"]
  accion:
    tipo: control_quimico_selectivo
    herbicida: "topramezone 33,6 g i.a./ha + atrazina 0,9 kg i.a./ha"
    ventana_dias: 5
    referencia: "Sanchez Ducca et al., 2020 - Sugar Tech"

- id: alerta_estres_hidrico
  condicion:
    NDWI_mean: { lt: 0.1 }
    SMAP_zona_radicular: { lt: 0.18 }
    precipitacion_7d_mm: { lt: 10 }
  accion:
    tipo: monitoreo_estres_hidrico
```

prioridad: media

3.4 Fragmento del JSON de salida

```
{
  "id_parcela": "TUC-LCO-0421-A3",
  "estadio_fenologico": { "clase": "gran_crecimiento", "confianza": 0.91 },
  "cobertura_dosel_pct": 82.4,
  "malezas": {
    "cobertura_total_pct": 8.6,
    "categorias_detectadas": [
      { "nombre_cientifico": "Cynodon dactylon",
        "cobertura_pct": 4.1, "n_parches": 27, "confianza_prom": 0.87 },
      { "nombre_cientifico": "Sorghum halepense",
        "cobertura_pct": 2.8, "n_parches": 14, "confianza_prom": 0.81 }
    ]
  },
  "recomendaciones": [{
    "tipo": "control_quimico_selectivo",
    "prioridad": "alta",
    "ahorro_estimado_pct": 71,
    "mapa_prescripcion_url": "/api/v1/parcelas/.../prescription.geojson"
  }]
}
```

4. Limitaciones y Alcance

Se declaran explícitamente las siguientes limitaciones, con el objeto de dar rigor académico a la evaluación del sistema:

Limitación	Observación y mitigación
Cámara RGB sin banda NIR	No permite NDVI directo desde el dron. Se compensa con índices visibles (ExG, MGRVI, GLI) e integración con Sentinel-2 a 10 m.
Dataset local aún pequeño	Los datasets globales (DeepWeeds, CropAndWeed) no representan las especies tucumanas. Se planifica un dataset propio de 500-800 imágenes para fine-tuning.
Problema green-on-green	La similitud espectral caña/maleza es el principal desafío reconocido en la literatura (npj AI 2026; IEEE J-STARS 2024). Las métricas alcanzables serán inferiores a las publicadas en datasets controlados.
No reemplaza al agrónomo	El sistema es un soporte de decisión. Las recomendaciones deben ser validadas por un profesional habilitado. El motor de reglas es editable y trazable.
Malezas tempranas (<2 cm)	La resolución a 80 m AGL (~2,5 cm/px) puede no detectar plántulas recién emergidas. El foco está en estadios ≥2 hojas verdaderas.
Métricas de rendimiento reportadas con cautela	Los valores mAP@0.5 de la literatura (YOLOv9: 0,935; Detectron2: 0,821) corresponden a 5 especies de Norteamérica (Sharma et al., 2024), no a caña de Tucumán.

5. Plan de Trabajo

El proyecto se desarrolla en cinco fases sobre 11 meses académicos. Los criterios de éxito son medibles y definidos a priori:

Fase	Meses	Actividades principales	Criterios de éxito
F1	1-2	Definición de requisitos, firma de convenios con INTA/EEAOC, repositorio Git, ambiente Docker reproducible, acceso GEE confirmado.	Repos creados; convenio firmado; plan de vuelo agendado.
F2	2-5	Vuelos piloto en ≥ 3 lotes, ortomosaicos ODM, etiquetado de dataset local (≥ 500 imágenes con bounding boxes, ≥ 150 con máscaras), pipeline ETL en PostGIS.	Dataset balanceado (≥ 80 imgs/clase); acuerdo inter-anotador $\kappa \geq 0,7$.
F3	4-7	Entrenamiento YOLOv8/v11 con cross-validation 5-fold, DeepLabV3+ para segmentación, clasificador de estadio fenológico, comparativa con baseline Faster R-CNN.	mAP@0.5 $\geq 0,75$ en dataset propio; F1 $\geq 0,7$ para Cynodon y Sorghum; mIoU segmentación $\geq 0,70$; inferencia < 100 ms/tile CPU.
F4	6-9	Conectores estables a GEE, Copernicus, SMAP, Open-Meteo, NASA POWER; motor de reglas validado por agrónomo INTA; generación reproducible del JSON; pruebas de carga.	Latencia end-to-end ≤ 12 h para parcela de 10 ha; $r \geq 0,6$ en validación cruzada de estrés hídrico vs. tensiómetros INTA.
F5	9-11	Dashboard web Leaflet + plugin QGIS; despliegue VM con docker-compose; pruebas con 2-3 productores tucumanos; documentación técnica y defensa.	SUS (System Usability Scale) ≥ 70 con productores; ≥ 3 ciclos completos cerrados; publicación académica (póster o paper).

6. Impacto Esperado

6.1 Beneficio económico para el productor

La literatura reporta ahorros del 20-35 % en herbicidas para aplicaciones de tasa variable (INTA AgTech; Larrazabal et al., Land 2024). Para un cañero con 100 ha y un costo anual de control de malezas de USD 80-150/ha, esto representa un ahorro potencial de USD 1.600-5.250 por campaña. La identificación y el tratamiento temprano de parches de Cynodon y Sorghum permite recuperar rendimiento: las pérdidas documentadas llegan a 21,44 t/ha (EEAOC, Avance 2023); a precio de caña 2024 (≈ 35 -50 USD/t bruta), el upside por hectárea es significativo. Adicionalmente, se reducen las horas-máquina y la presión selectiva sobre poblaciones de malezas, disminuyendo el riesgo de resistencia a glifosato, documentada en Sorghum halepense en Argentina.

6.2 Escalabilidad

El stack es agnóstico al cultivo. Con el reentrenamiento del modelo de visión computacional, la plataforma es transferible a limón (Tucumán es el primer exportador mundial), arándano, frutilla, tabaco, soja y garbanzo en el NOA, así como a viñedo y olivo en Mendoza. La arquitectura distribuida es escalable a nivel provincial mediante convenios existentes del INTA con FEARCA y universidades nacionales. El repositorio público (AGPL-3.0) permite que otros grupos del NOA extiendan los resultados sin barreras de licenciamiento.

7. Referencias

1. IPAAT (2024). Reporte final de zafra 2024. Instituto Provincial de Acción Integral para el Azúcarero Tucumano. <https://www.ipaat.gov.ar>
2. EEAOOC / Revista Avance (2023). Relevamiento de malezas en caña de azúcar en Tucumán. Estación Experimental Agroindustrial Obispo Colombes.
3. Olsen, A. et al. (2019). DeepWeeds: A Multiclass Weed Species Image Dataset for Deep Learning. *Scientific Reports*, 9, 2058.
4. Sharma, A., Kumar, V., Longchamps, L. (2024). Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN for detection of multiple weed species. *Smart Agricultural Technology*, 9.
5. Sánchez Ducca, A. et al. (2020). Topramezone: New Herbicide Registered in Sugarcane for Post-emergent Management of *Cynodon dactylon* in Tucumán, Argentina. *Sugar Tech*.
6. Cabrera, D.C., Juárez Ansonnaud, R., Varela, A.E. (2020). Análisis de la comunidad de malezas en dos edades de corte de caña de azúcar. *RANAR*, 40(1), 31-38.
7. Sa, I. et al. (2018). WeedMap: A large-scale semantic weed mapping framework using aerial multispectral imaging and deep neural network. *Remote Sensing*. arXiv:1808.00100.
8. Larrazabal, M. et al. (2024). Developing Site-Specific Prescription Maps for Sugarcane Weed Control Using High-Spatial-Resolution Images and LiDAR. *Land*, 13(11), 1751.
9. Rocha, F. et al. (2024). Evaluation of Sugarcane Crop Growth Monitoring Using Vegetation Indices from RGB-Based UAV Images. *Agronomy*, 14(9), 2059.
10. Kumar, S. et al. (2023). Concealed nature of weed in sugarcane: Deep Neural Networks for Identifying Small Weed Patches Using Drone Images. *IEEE J-STARS*.
11. Barbosa Júnior, M.R. et al. (2022). UAVs to Monitor and Manage Sugarcane: Integrative Review. *Agronomy*, 12(3), 661.
12. Toward autonomous weed management systems in sugarcane crops and an assessment of technological readiness (2026). *npj Artificial Intelligence*.